

神经网络第五章

2022年7月14日 星期四 13:52

1. Train / Dev / Test sets

训练, 验证, 测试

Best output \rightarrow 无偏估计.

(Train : Test = 3 : 1)

(Train : Dev : Test = 6 : 2 : 2)

Big data sample : (98% : 1% : 1%)

或 (99% : 0.5% : 0.5%)

2. Bias / Variance.

high bias \rightarrow 欠拟合

high variance \rightarrow 过拟合...

避免 high bias: 增加隐藏层个数, 神经元个数

训练时间 \uparrow , 换用更复杂的 NN

避免 high variance: 增加训练样本数据, 或进行

正则化 Regularization.

(L_2 regularization)

$$J(W, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) + \frac{\lambda}{2m} \|W\|_2^2$$

$$\|W\|_2^2 = \sum_{j=1}^n w_j^2 = W^T W$$

(L_1 regularization)

$$J(W, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) + \frac{\lambda}{2m} \|W\|_1$$

$$\|W\|_1 = \sum_{j=1}^n |w_j|$$

加 λ 正则化项后.

$$dW^{[L]} = dW_{\text{before}}^{[L]} + \frac{\lambda}{n_2} W^{[L]}$$


$$W^{[L]} := W^{[L]} - \alpha dW^{[L]}$$

L_2 regularization \rightarrow weight decay.

$$W^{[L]} := W^{[L]} - \alpha dW^{[L]}$$

$$= W^{[L]} - \alpha (dW_{\text{before}}^{[L]} + \frac{\lambda}{m} W^{[L]})$$

$$= (1 - \alpha \frac{\lambda}{m}) W^{[L]} - \alpha dW_{\text{before}}^{[L]}$$



dropout regularization:

训练过程中, 对于每层神经元, 按照一

定概率将其从神经网络中丢弃

达到简化模型的效果, 来避免过拟合

$$dl = np.random.randn(a1.shape[0], a1.shape[1]) < \text{keep-prob}$$

$$a1 = np.multiply(a1, dl)$$

$$a1 /= \text{keep-prob.}$$

(设定 keep-prob = 0.8)

Other regularization methods

① 对已有样本进行处理 \rightarrow 更多样本

"猫" 图片进行水平翻转, 垂直翻转,

任意角度旋转, 缩放, 扩大...

(不需要增加额外成本, 却能防止过拟合...)

② 增加一些 noise

③ 防止过拟合, 提前 "early stopping"

Normalizing inputs.

$$\mu = \frac{1}{m} \sum_{i=1}^m x^{(i)} \quad \sigma^2 = \frac{1}{m} \sum_{i=1}^m (x^{(i)})^2$$

$$X = \frac{X - \mu}{\sigma}$$

$$x_1 \in [1, 1000], x_2 \in [0, 1]$$


让输入归一化同样的尺度上...

由于 w_1, w_2 数值差异很大, 只能选择很小的学习因子

避免振荡

Vanishing and Exploding gradients

eg:



$$\hat{y} = W^{[L]} W^{[L-1]} W^{[L-2]} \dots W^{[3]} W^{[2]} W^{[1]} X$$

L 非常大时, 让某些过大或过小

Weight Initialization for Deep Networks

改善梯度爆炸问题方法.

$$z = w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$

$$a = g(z)$$

(让 w 与 n 有关, n 越大, x 越小)

$$W^{[L]} = np.random.randn(n[L], n[L-1]) * np.sqrt(1/n[L-1])$$

(激活函数此时为 $\tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$)


$$W^{[L]} = np.random.randn(n[L], n[L-1]) * np.sqrt(2/n[L-1])$$

(激活... 为 ReLU)



$$W^{[L]} = np.random.randn(n[L], n[L-1]) * np.sqrt(2/n[L-1] * n[L])$$

Numerical approximation of gradients



$$g(\theta) = \frac{f(\theta + \epsilon) - f(\theta - \epsilon)}{2\epsilon}$$

其中 ϵ 足够小.

Gradient checking

$$d\theta_{\text{approx}}[i] = \frac{J(\theta_1, \theta_2, \dots, \theta_i + \epsilon, \dots) - J(\theta_1, \theta_2, \dots, \theta_i - \epsilon, \dots)}{2\epsilon}$$

$$\frac{\|d\theta_{\text{approx}} - d\theta\|_2}{\|d\theta_{\text{approx}}\|_2 + \|d\theta\|_2}$$

故其距离越小,

则反向梯度计算, 则无 bugs

Grad checking Implementation

① 不要整个过程都梯度, 仅作为 debug

② 不要忽略正则化项

③ 梯度检查时关闭 dropout, 完成后打开 dropout

④ 开始检查, 一段时间再检查